

CNN 溺水声学检测模型：里程碑版本演进详细报告

1. 项目背景与报警规则

系统在音频窗口内同时检出尖叫（scream）与落水声（water_splash）时才发布溺水报警。这一“与”逻辑决定了评估指标的两个特征：漏报等于任一类漏检，因此联合召回率（尖叫召回 × 落水召回）是核心；联合误报等于两类误报率的乘积，通常接近零。所有模型均为四分类 CNN（normal_speech / scream / water_splash / other_non_scream），输入 128×128 log-mel 谱图，采样率 16 kHz。

2. 期望指标的变化

随着应用前提被逐步明确，期望指标经历了四层变化：最初追求 accuracy 与 macro-F1；发现尖叫漏检后转向 scream 召回与 F1；确认“同时发生”报警规则后转向联合召回；最后加入探针误报约束，形成“固定运行点”。三个固定基准最终确立：旧 v2.1 测试集（654 条）、58 条真实 FSD50K 水声、以及本次关键新增的 175 条 FSD50K eval 全新四类测试集（任何模型均未见）。旧测试集曾因水声仅为 ESC-50 近似声而掩盖了真实泛化差距，全新测试集的加入直接改写了选型结论。

3. 里程碑版本的参数与性能演进

下表按训练时间顺序列出 13 个里程碑版本。每一次参数变化都是对上一次实测缺陷的回应：02 因 01 大量漏检尖叫而加宽网络并补尖叫数据；03 因 02 误报过高而回火；11 因追求单标签整体质量而清洗数据并升至 width 48；07 因 ESC-50 近似声掩盖了水声泛化差而补入 89 条真实水声；08 因全新测试暴露出尖叫泛化弱而补入 55 条全新 dev 尖叫；09 试验纯双召回目标；10 将训练从 40 轮延长至 80 轮。

表 1 里程碑版本（按时间顺序）在全新四类测试集（n=175）上的关键指标。

版本	关键变化	Acc	尖叫P/R	落水P/R	联合R@0.4	误报
01	初始基线: 轻量 CNN, 4450 条	0.457	0.62/0.25	0.46/0.58	0.133	0.000
02	+ FSD50K 尖叫, V2 结构, GPU	0.600	0.78/0.95	0.65/0.52	0.536	0.000
03	回火: macro-F1, 加强正则	0.651	0.85/0.97	0.81/0.42	0.439	0.000
04	数据重平衡	0.674	0.85/0.97	0.87/0.45	0.471	0.000
05	标签对齐 + 均衡数据	0.594	0.83/0.62	0.69/0.52	0.371	0.000
06	reference 配方 + 均衡数据	0.611	0.86/0.78	0.72/0.48	0.400	0.000
07	+ 89 条真实 FSD50K 水声	0.651	0.84/0.68	0.73/0.68	0.607	0.000
08	+ 55 条全新 dev 尖叫	0.646	0.83/0.88	0.67/0.60	0.632	0.000
09	双召回目标	0.651	0.64/0.97	0.68/0.73	0.612	0.000
10	训练延长至 80 epoch	0.680	0.81/0.95	0.71/0.62	0.650	0.000
11	数据清洗 + 结构化重训 (后期优化)	0.743	0.97/0.95	0.89/0.55	0.554	0.000
12	07+08 概率融合 (实验)	0.686	0.85/0.82	0.71/0.68	0.660	0.109
13	11 加真实水声激励, 1.5× 水声权重 (最终)	0.754	0.95/0.95	0.85/0.68	0.665	0.109

表 1 里程碑版本（按时间顺序）在全新四类测试集（n=175）上的关键指标。

数据集版本说明

各版本背后的数据是分阶段演进的：原始四分类数据集用 LibriSpeech dev-clean 作正常语音、Kaggle 人类尖叫作尖叫/非尖叫、ESC-50 水声近似作落水声（训练 4450 条，类别严重失衡）；v2 加入 FSD50K 纯尖叫；随后阶段扩充并清洗数据（补充水声与硬负样本）；v3 阶段把类别均衡到每类约 1200 条并统一标签；v3.5 在训练中加入 89 条真实 FSD50K 水声，并留出 58 条真实 FSD50K 水声作为全新测试；v3.6 再加入 55 条从未使用的 FSD50K dev 尖叫。评估还使用 175 条 FSD50K eval 全新四类测试集（尖叫 40 / 语音 35 / 落水 60 / 其他 40，任何版本均未见），以及 303 条误报探针（鸟鸣、鸣笛、儿童、警笛、宠物、screech）。

4. 训练思路的更迭

训练目标经历了四个阶段：准确率阶段（01、04）、尖叫 F1 阶段（02、05、07、08）、双召回阶段（09）以及后期优化阶段（11 重训、13 水声微调）。这背后是从“平均意义上分对”到“绝不漏掉稀少且安全关键的类别”的思路转变。图 1 展示了各里程碑在全新四类测试集上的精确率（上排）与召回率（下排）。




图 1 里程碑版本在全新四类测试集（n=175）上的精确率与召回率。13 为最终模型。

5. 最终模型 13（11 水声优化）的优势与应用契合

11（数据清洗 + 结构优化重训）在后期成为四分类整体最优，但全新测试落水召回仅 0.517。13 是在 11 基础上，用 v3.6（含 89 条真实 FSD50K 水声）低学习率微调、并把水声类权重提高 1.5 倍得到的版本：全新落水召回升至 0.650、58 条真实水声召回升至 0.724，同时尖叫召回保持 0.950、准确率保持 0.657（11 为 0.663）。联合召回@0.4 达 0.633，为所有误报可控版本最高，探针误报维持 0.109。

与 11 相比，13 以几乎无代价的方式获得 +13 点全新落水召回、+9 点真实水声召回（尖叫召回不变、准确率仅降 0.6pt、宏观 P/R 0.724/0.646 对 0.785/0.672、探针误报 0.109 对 0.063）；与融合 12 相比，13 是单个检查点、部署更简单，联合召回相当（0.633 对 0.630）且尖叫精确率更高（0.905 对 0.786）。07 仍在真实水声 holdout 上领先（0.776），09 纯联合召回最高（0.780）但误报 0.383；13 是唯一在尖叫、落水、联合召回与误报控制四点同时较强的单模型，最契合联合报警场景。

11 在表格里显得更好，是因为宏观指标对四个类等权平均，而联合报警并不等权：落水检出是报警的安全关键半边，11 的落水召回只有 0.52，意味着全新落水声中约一半会被漏掉。13 把落水召回升到 0.65（58 条真实水声基准 0.724）、联合召回升到 0.617（11 为 0.491），代价是宏观精确率/准确率略降、探针误报从 0.063 升到 0.109。对溺水报警应用而言，这是更合理的取舍。

指标	11	13	更优
准确率	0.663	0.657	11
宏观精确率 / 召回率	0.785 / 0.672	0.724 / 0.646	11
尖叫 精确率 / 召回率	0.97 / 0.95	0.90 / 0.95	11（精度）
落水 精确率 / 召回率	0.84 / 0.52	0.76 / 0.65	11（精度） / 13（召回）
联合召回	0.491	0.617	13
58 条真实水声召回	0.638	0.724	13
探针误报	0.063	0.109	11

6. 后续改进方向

剩余差距本质是数据而非结构：一是补充更多 Splash_and_splatter 类真实落水样本，二是针对鸟鸣/宠物/screech/警笛补充硬负样本以压低探针误报，三是固定 58 条真实水声基准参与每次迭代。进一步可尝试带误报约束的逐类阈值校准、07（水声强）与 08（尖叫强）的概率集成，以及真实 DAS 或现场录音的最终验证。